

基于 LSTM 的空气质量 ($PM_{2.5}$) 预测报告

22375126 吴尔伦

日期: 2025年4月30日

报告目的: 本报告旨在详细阐述使用长短期记忆 (LSTM) 神经网络模型, 根据历史天气条件和污染水平, 预测未来 $PM_{2.5}$ 浓度的过程、结果与分析。

概要:

本项目利用 Kaggle 提供的包含五年逐时空气质量和气象数据的北京 $PM_{2.5}$ 数据集, 构建了一个 LSTM 时间序列预测模型。目标是根据过去几小时 (例如3小时) 的天气指标 (露点、温度、气压、风向、风速、累积降雪/降雨) 和 $PM_{2.5}$ 浓度, 预测下一小时的 $PM_{2.5}$ 浓度。通过数据清洗、特征编码、数据归一化、序列构建等预处理步骤, 我们准备了适用于 LSTM 的数据格式。随后, 我们使用 PyTorch 框架构建、训练并评估了 LSTM 模型。评估结果 (以反归一化后的实际 $PM_{2.5}$ 单位衡量) 显示, 模型能够捕捉 $PM_{2.5}$ 变化的基本趋势, 其均方根误差 (RMSE) 和平均绝对误差 (MAE) 表明预测具有一定的准确性, 但在预测极端峰值时存在挑战。本报告将详细介绍整个流程, 展示关键结果的可视化图表, 并讨论模型的性能、局限性及未来改进方向。

1. 引言

1.1 背景

空气质量, 特别是细颗粒物 ($PM_{2.5}$) 的浓度, 直接关系到公众健康和环境福祉。高浓度的 $PM_{2.5}$ 会导致呼吸系统和心血管系统疾病, 降低能见度, 并对生态系统产生负面影响。因此, 准确预测 $PM_{2.5}$ 浓度对于预警、制定缓解措施以及公众健康防护至关重要。

1.2 问题陈述

本项目旨在解决一个时间序列预测问题: 能否利用历史多变量 (气象因素和过去的污染水平) 数据, 有效预测下一小时的 $PM_{2.5}$ 浓度?

1.3 项目目标

- 探索和理解空气质量数据集的特性。
- 掌握数据预处理技术, 包括处理缺失值、编码分类特征和数据归一化。
- 学习并应用 LSTM 神经网络构建时间序列预测模型。
- 评估模型在预测 $PM_{2.5}$ 浓度方面的性能。
- 分析模型结果, 理解其优势与局限性。

1.4 数据集描述

我们使用的是来自 Kaggle 的“Beijing PM2.5 Data Set”。该数据集包含了从 2010 年到 2014 年五年间，北京某监测站逐小时记录的气象数据和空气质量数据。关键特征包括：

- date：日期和时间戳 (YYYY-MM-DD HH:MM:SS)
- pollution ($PM_{2.5}$): $PM_{2.5}$ 浓度 ($\mu\text{g}/\text{m}^3$) - 这是我们的预测目标
- dew：露点温度 ($^{\circ}\text{C}$)
- temp：温度 ($^{\circ}\text{C}$)
- press：气压 (hPa)
- wnd_dir：组合风向 (如 SE, NW, cv 等) - 分类特征
- wnd_spd：风速 (m/s)
- snow：累积小时降雪量 (mm)
- rain：累积小时降雨量 (mm)

[数据样本展示]

date	pollution	dew	temp	press	wnd_dir	wnd_spd	snow	rain
2010-01-02 00:00:00	129.0	-16	-4.0	1020.0	SE	1.79	0	0
2010-01-02 01:00:00	148.0	-15	-4.0	1020.0	SE	2.68	0	0
...	...	...	...	...	...	...	...	...

2. 方法论


2.1 数据预处理

原始数据需要经过一系列处理才能用于 LSTM 模型：

1. **加载与解析:** 使用 Pandas 加载数据，将 date 列解析为日期时间对象并设为索引。
2. **缺失值处理:** 为防止各列存在缺失值 (NaN)。我们采用了前向填充 (ffill) 策略来填充大部分缺失值，对于数据集开头的少量 NaN 用 0 填充。检查并处理其他列的缺失值。
3. **特征编码:** 风向 wnd_dir 是分类特征。我们使用**One-Hot 编码**将其转换为多个二元数值特征（如 wnd_SE，wnd_NW 等），使模型能够处理这些信息。

4. **数据归一化:** 由于不同特征的数值范围差异很大（如气压上千，温度为个位数），我们使用 Scikit-learn 的 `MinMaxScaler` 将所有数值特征缩放到 $[0, 1]$ 区间。这有助于神经网络模型的稳定训练和快速收敛。我们保存了 `scaler` 对象，以便后续将预测结果反归一化。

[建议图表 2: 数据预处理流程图]



2.2 特征工程：序列构建

LSTM 处理的是序列数据。我们需要将时间序列数据构造成监督学习的格式。我们定义了一个“回看窗口”(lookback window, n_steps)，例如 $n_steps = 3$ 。这意味着我们使用过去 3 个小时的所有特征数据作为输入 (X)，来预测第 4 个小时（即当前时间步 + 1）的 $PM_{2.5}$ 值作为输出 (y)。

- **输入 (X):** 形状为 (样本数, n_steps , 特征数) 的三维数组。
- **输出 (y):** 形状为 (样本数,) 或 (样本数, 1) 的一维或二维数组，包含每个输入序列对应的下一小时 $PM_{2.5}$ 目标值（已归一化）。

2.3 模型架构：LSTM

LSTM 特别擅长捕捉时间序列数据中的长期依赖关系。与简单的 RNN 不同，LSTM 拥有“门控”机制（输入门、遗忘门、输出门），可以有效地学习何时保留信息、何时遗忘信息，从而避免梯度消失/爆炸问题。

模型结构大致如下：

1. **输入层:** 接收形状为 (n_steps , $n_features$) 的输入序列。
2. **LSTM 层 1:** 包含若干 LSTM 单元，激活函数通常为 `relu` 或 `tanh`。`return_sequences=True`（如果后面还有 LSTM 层）。
3. **Dropout 层:** 以一定比例（例如 20%）随机失活神经元，防止过拟合。
4. **LSTM 层 2:** 增加模型容量，捕捉更复杂的模式。
5. **Dropout 层:** 进一步防止过拟合。
6. **全连接层:** 将 LSTM 最后一层的输出映射到最终的预测目标。由于我们只预测一个值 ($PM_{2.5}$)，该层只有一个神经元。

2.4 训练过程

1. **数据划分:** 将构建好的序列数据按时间顺序划分为训练集（例如前 80%）和测试集（例如后 20%）。
2. **模型编译/配置:**

- **损失函数 (Loss Function):** 选择均方误差 (Mean Squared Error, MSE)，这是回归任务的标准损失函数。
- **优化器 (Optimizer):** 使用 Adam 优化器，它是一种高效且常用的梯度下降优化算法。
- **评估指标 (Metrics):** 除了损失函数，我们还监控平均绝对误差 (Mean Absolute Error, MAE)，它提供了更直观的误差度量。

3. **模型训练:** 使用训练集数据对模型进行多轮训练。在每个 epoch 中，数据被分成小批量进行处理。我们监控训练损失和验证损失来观察模型的学习进程。

2.5 工具与库

- **编程语言:** Python 3.12.7
- **核心库:**
 - Pandas: 数据加载、处理和操作。
 - NumPy: 高效的数值计算。
 - Scikit-learn: 数据预处理（归一化、编码）、模型评估指标。
 - PyTorch: 构建和训练 LSTM 模型。
 - Matplotlib: 数据可视化（绘制结果图）。

3. 结果与讨论

3.1 模型性能


模型在测试集上进行了评估。为了更直观地理解预测误差，我们将归一化的预测值和真实值通过之前保存的 `scaler` 反归一化回原始的 $PM_{2.5}$ 浓度单位 ($\mu\text{g}/\text{m}^3$)。关键性能指标如下：

[模型在测试集上的性能指标]

指标	数值 (示例)	单位	描述
均方根误差 (RMSE)	37.39	$\mu\text{g}/\text{m}^3$	预测误差的标准差，对大误差敏感
平均绝对误差 (MAE)	28.59	$\mu\text{g}/\text{m}^3$	平均预测误差的绝对值，更直观
测试集损失 (MSE - Scaled)	0.001415	-	归一化尺度上的均方误差

3.2 可视化分析


[实际 vs. 预测 $PM_{2.5}$ 浓度 (测试集)]



图表分析: 从图表可以看出:

- 模型的预测（红色曲线）在总体趋势上能够较好地跟随实际 $PM_{2.5}$ 浓度（蓝色曲线）的变化。
- 模型能捕捉到污染水平的上升和下降周期。
- 然而，在 $PM_{2.5}$ 浓度出现急剧上升的峰值或快速下降的谷值时，模型的预测往往显得较为平滑，可能无法完全捕捉到这些极端变化。预测值通常比实际峰值低，比实际谷值高。
- 整体而言，预测曲线与实际曲线的贴合程度印证了 MAE 和 RMSE 指标所反映的预测精度。

[训练过程损失曲线]



图表分析: 从图表可以看出:

- 训练损失 (Training Loss) 随着训练轮数的增加而稳步下降, 并最终趋于平稳, 表明模型在训练数据上进行了学习和收敛。
- 如果包含验证损失 (Validation Loss), 观察它是否也随之下降并趋于平稳。如果验证损失在训练后期开始上升, 则可能表示出现了过拟合。根据曲线走势, 可以判断训练是否充分, 或者是否需要提前停止训练或调整模型复杂度/正则化策略。

3.3 结果讨论

综合性能指标和可视化图表, 我们可以认为所构建的 LSTM 模型在预测下一小时 $PM_{2.5}$ 浓度方面取得了一定的成功。平均绝对误差 (MAE) 约为 $28.59 \mu\text{g}/\text{m}^3$, 这意味着平均而言, 模型的预测值与实际值相差约 $28.59 \mu\text{g}/\text{m}^3$ 。考虑到 $PM_{2.5}$ 浓度本身波动范围较大, 这个误差水平在某些应用场景下可能是可以接受的, 但对于需要精确峰值预测的场景则有待提高。模型对趋势的良好捕捉能力证明了 LSTM 处理时间依赖性的有效性。预测未能完全匹配峰值的问题是时间序列预测中的常见挑战, 可能与模型容量、特征信息或数据本身的噪声有关。

4. 结论与未来工作

4.1 结论

本项目成功应用 LSTM 神经网络处理了多变量时间序列数据, 实现了对未来 $PM_{2.5}$ 浓度的预测。通过细致的数据预处理和模型构建, 我们得到的模型能够捕捉 $PM_{2.5}$ 浓度的主要变化趋势, 并提供了具有一定参考价值的预测结果。结果表明, 结合历史气象信息和污染水平, LSTM 模型是解决此类预测问题的有效工具。

4.2 局限性

- **数据局限:** 数据仅来源于北京一个站点, 可能不具有广泛代表性。数据时间跨度为五年, 可能未包含所有极端天气或政策影响事件。
- **模型简化:** 本项目中的 LSTM 结构相对基础, 未进行详尽的超参数调优 (如 LSTM 单元数、层数、学习率、`n_steps` 等)。
- **特征工程有限:** 未探索更复杂的特征组合或引入外部特征 (如节假日信息、区域排放源信息等)。

4.3 未来方向

- **超参数优化:** 使用网格搜索、随机搜索或贝叶斯优化等方法系统地寻找最佳模型配置。
- **模型架构探索:** 尝试更复杂的 LSTM 变体 (如 Bi-LSTM, Attention-LSTM) 或结合 CNN 等其他网络结构 (CNN-LSTM) 来提取更丰富的时空特征。
- **特征工程深化:** 创造基于时间的特征 (如一天中的小时、星期几、月份), 或引入其他相关数据源。
- **多步预测:** 调整模型结构 (如使用 Seq2Seq 模型) 以实现对未来多个时间步的预测。

- **模型可解释性:** 使用 SHAP 或 LIME 等技术尝试理解模型做出特定预测的原因，哪些特征影响最大。
- **跨站点/城市研究:** 将模型应用于更多地点的数据，验证其泛化能力。